



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331,CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：面向复杂环境的轻量化无人机小目标检测协同优化方法
作者：王浩，刘静，田锦，贺立，Huaglory Tianfield
网络首发日期：2026-09-01
引用格式：王浩，刘静，田锦，贺立，Huaglory Tianfield. 面向复杂环境的轻量化无人机小目标检测协同优化方法[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.tp.20260831.1352.010>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

面向复杂环境的轻量化无人机小目标检测协同优化方法

王浩¹, 刘静¹⁺, 田锦², 贺立¹, Huaglory Tianfield³

1.金陵科技学院 网络与通信工程学院 211169

2.电子科技大学 智慧信息系统产业技术研究院, 四川 宜宾 644005

3.格拉斯哥卡利多尼亚大学 计算机工程与建筑环境学院

+ 通信作者 E-mail: liuj608@jit.edu.cn

摘要: 复杂环境(如植被茂密、背景杂乱)中无人机检测面临尺度极小、背景干扰强、伪装效应显著三重耦合难题,导致现有检测方法漏检率高、计算开销大。针对上述挑战,本文提出一种基于YOLOv11n的任务驱动的轻量化协同优化无人机目标检测算法。首先,设计C2PSA-TripleAttention模块,通过跨维度注意力显式建模无人机旋翼的正交几何先验,在纹理缺失区域重建判别性结构响应,从根本上抑制伪装效应;其次,构建Detect-MBConv轻量化检测头,新增高分辨率P2分支并优化双向融合路径,在保留小于8像素目标细节特征的同时降低计算量;最后,引入Focaler-IoU损失函数,聚焦 $\text{IoU} \in [0, 0.95]$ 的样本,持续优化微小的定位偏差,有效解决传统损失函数在高重叠区域梯度消失的问题。实验结果表明,本方法在DUT反无人机数据集上 $\text{mAP}@0.5$ 达90.2%,较YOLOv11n提升8.3个百分点,召回率提升11个百分点,精确率达96.3%。与RT-DETR(108M)、YOLOv9c(103.7M)等百兆级大模型相比,本方法参数量仅1.68M(较YOLOv11n降低35.5%),检测精度更高,计算开销更低,为边缘端反无人机系统提供了高精度、轻量化的可行解决方案。

关键词: 反无人机; 小目标检测; YOLOv11n; 三重注意力; 轻量化检测头

文献标志码: A **中图分类号:** TP391.4 **doi:** 10.3778/j.issn.1002-8331.2601-0055

Collaborative Optimization Method for Lightweight Small Target Detection of UAVs in Complex Environments

WANG Hao¹, LIU Jing¹⁺, TIAN Jin², HE Li¹, Huaglory Tianfield³

1. School of Network and Communication Engineering, Jinling Institute of Technology, 211169

2. Institute of Intelligent Information Systems Industry Technology, University of Electronic Science and Technology of China, Yibin, Sichuan, 644005

3. School of Computing, Engineering and Built Environment, Glasgow Caledonian University

Abstract: UAV detection in complex environments such as dense vegetation and cluttered backgrounds faces three intertwined challenges: extremely small scales, strong background interference, and significant camouflage effects, resulting in high miss rates and substantial computational overhead in existing methods. To address these challenges, a task-driven lightweight collaborative optimization UAV object detection algorithm based on YOLOv11n is proposed. First, a C2PSA-TripleAttention module is designed to explicitly model the orthogonal geometric priors of UAV rotors through a cross-dimensional attention mechanism, reconstructing discriminative structural responses in texture-deficient regions to fundamentally suppress camouflage interference. Second, a Detect-MBConv lightweight detection head is constructed, introducing a high-resolution P2 branch and optimizing the bidirectional fusion path to preserve detailed features of targets smaller than 8 pixels while reducing computational cost. Finally, the Focaler-IoU loss function is introduced to focus on medium-difficulty samples within the IoU interval of $[0, 0.95]$, continuously optimizing minor localization deviations and overcoming the gradient vanishing problem of traditional losses in high-overlap regions. Experimental results demonstrate that the

基金项目: 南京市重大科技专项项目(202309010); 国家外国专家项目(H20240373); 金陵科技学院高层次人才科研启动项目(jit-b-201632); 国家级大学生创新创业训练计划项目(202513573036X)。

作者简介: 王浩(2001—),男,硕士研究生,CCF学生会员,研究方向为目标识别;刘静(1983—),女,博士,副教授,研究方向为图像处理、通信感知一体化;田锦(1963—),男,博士,教授,研究方向为通信感知一体化、智能交通、泛在异构无线网络;贺立(2005—),男,本科生,研究方向为图像处理、雷达信号处理;Huaglory Tianfield(1965—),男,博士,教授,研究方向为人工智能、图像处理、云计算等。

proposed method achieves 90.2% mAP@0.5 on the DUT Anti-UAV dataset, which is 8.3 percentage points higher than YOLOv11n, with an 11-percentage-point improvement in recall and a precision of 96.3%. Compared with hundred-mega-byte-level large models such as RT-DETR (108M) and YOLOv9c (103.7M), the proposed method has only 1.68M parameters (35.5% less than YOLOv11n), while achieving higher detection accuracy and lower computational cost, providing a solution that balances accuracy and lightweight for edge-side anti-UAV systems.

Key words: anti-UAV; small target detection; YOLOv11n; triple attention; lightweight detection head

无人机凭借其体积小、机动性强、成本低等优势,已广泛应用于交通监控、环境监测、灾害救援与精准农业等领域^[1]。然而,随着无人机数量的激增,由其引发的空域安全与隐私泄露问题日益凸显。近年来,多起无人机非法入侵事件表明,发展高效、可靠的无人机检测技术已成为保障低空空域安全的重要手段。

目前,无人机检测主要依赖雷达、声学、射频与视觉等技术。雷达探测受天气条件影响较小,但对微型无人机识别能力有限^[2];声学探测成本较低,但易受环境噪声干扰^[3];射频探测依赖于无人机信号,在无线电静默状态下失效^[4]。相比之下,视觉探测具有成本低、信息直观等优势,已成为反无人机研究的主流方向。

然而,在植被茂密、背景复杂等场景下,无人机目标检测主要面临以下三个方面的挑战:(1)目标尺度极小:无人机在图像中常仅占数个像素(通常小于 30×30 像素),导致深层特征图中几何信息严重丢失;(2)背景干扰强:树木、建筑等复杂背景中的高频纹理容易掩盖无人机目标特征,导致特征混淆与误检;(3)伪装效应显著:无人机颜色和纹理通常与背景相似,在低分辨率条件下易退化为近似均匀的纹理区域,从而造成定位偏差^[5]。

随着深度学习的发展,基于卷积神经网络的目标检测算法取得了显著进展。其中,YOLO(You Only Look Once)系列算法因具有端到端结构、推理速度快以及检测精度较高等优势,被广泛应用于无人机目标检测任务^[6-7]。近年来,研究者围绕YOLO系列模型,从注意力机制、特征金字塔、检测头设计以及损失函数等方面开展了大量研究,在一定程度上提升了无人机小目标的检测性能。但针对复杂环境下的小目标检测仍存在一定局限性。

针对无人机目标尺度极小导致的特征湮灭问题,现有研究主要通过多尺度特征融合和增加检测头来改善无人机小目标感知能力。文献^[8]提出BG-YOLO算法,针对低慢小无人机目标检测任务,在高分辨率特征层添加检测头,有效减少图像下采样过程中的信息丢失,显著提升了对小尺度无人机的检测能力。文献

^[9]设计的SRD-YOLOv5模型,通过尺度序列特征融合模块和多尺度特征提取模块,并引入极小目标检测层,在保留高分辨率特征的同时实现了对微尺度无人机目标的精准检测。然而,这些方法通常通过加深网络结构或增加检测分支来提升性能,但同时也导致模型计算复杂度和参数量增加,不利于边缘设备上的实时部署。此外,单纯增加检测头并未解决深层特征图中小于8像素目标的几何信息完全湮灭的问题。

针对无人机目标背景干扰强导致的特征混淆问题,研究者引入多种注意力机制以增强无人机目标区域响应、抑制背景噪声。文献^[10]提出的CAFE-YOLO算法,在骨干网络中引入通道注意力机制以增强关键特征的关注度,同时设计细粒度特征增强模块提取局部细节特征,有效提升了复杂背景下无人机的感知能力。文献^[11]针对红外无人机目标跟踪任务,提出动态特征融合网络,通过全局上下文注意力知识蒸馏增强模型对重要区域的关注,在复杂背景下实现了优于主流跟踪器的性能。然而,这些注意力机制多聚焦于单一维度,难以捕捉通道与空间之间的跨维度交互关系,在复杂背景与无人机目标频谱相似时,无法有效激活微弱但具有方向性的结构特征。

针对无人机目标伪装效应显著导致的定位偏差问题,损失函数的改进成为提升回归精度的关键。文献^[12]基于EED-YOLOv8n的无人机目标检测方法,采用EIoU损失函数替代CIoU,加快收敛速度并提升边界框回归精度。然而,对于无人机小目标,现有IoU类损失函数在高重叠区域容易出现梯度衰减。当目标尺寸约为 30×30 像素时,仅1~2像素的定位偏差即可导致IoU下降超过10%,而此时的梯度已趋近于零,模型难以进一步优化边界框定位精度。

针对上述不足,本文以轻量化YOLOv11n为基线模型,提出了一种任务驱动的轻量化无人机小目标检测算法,主要贡献如下:

(1)针对伪装效应显著导致的目标辨别困难,提出C2PSA-TripleAttention模块。通过跨维度注意力显式建模无人机旋翼的正交几何先验,在纹理缺失区域重

建判别性结构响应,从根本上抑制伪装干扰。

(2)针对目标尺度极小导致的信息湮灭问题,设计 Detect-MBConv 轻量化检测头。新增高分辨率 P2 分支 (160×160) 并优化双向融合路径,使小于 8 像素目标的细节特征得以保留且计算量降低。

(3)针对传统 IoU 损失在高重叠区梯度消失导致微小定位偏差难以优化的问题,引入 Focaler-IoU 损失函数,在训练后期持续提供有效梯度。

在公开 DUT Anti-UAV 数据集上的实验结果表明,所提出的各项改进能够协同提升模型性能,使模型在检测精度与轻量化之间实现了有效平衡,为边缘端反无人机目标检测提供了一种兼顾检测精度与计算效率的解决方案

1 YOLOv11 算法

YOLOv11n 是 Ultralytics 于 2024 年发布的轻量级单阶段目标检测模型^[13],采用 C3k2 主干网络结构、FPN+PAN 颈部网络及解耦检测头。相较于 YOLO 系列中其他模型,YOLOv11n 具有较高的检测精度和推理效率,在通用目标检测任务中实现了检测性能与计算效率之间的良好平衡。因此,本文选择 YOLOv11n 作为改进基础,构建兼顾检测精度、实时性和轻量化特性的无人机小目标检测模型。

然而,将 YOLOv11n 应用于复杂环境下的微小无人机目标检测任务时,其网络结构仍存在以下不足:

注意力机制缺乏跨维度建模:骨干末端的 C2PSA 模块采用逐点空间注意力 (PSA),仍以空间显著特征为主导,无法捕捉通道与空间的联合依赖。当无人机与背景频谱重叠时,微弱的方向性结构 (如旋翼) 难以被激活,导致伪装目标漏检。

检测头尺度与微小目标特征匹配不足:检测头仅利用 P3~P5 (尺寸分别为 80×80 、 40×40 、 20×20 像素) 特征图,小于 8 像素的目标在 P3 层中细节信息进一步衰减,旋翼等关键结构特征难以保留;同时,P5 分支主要面向大目标检测,在无人机小目标检测任务中的作用有限,却增加了模型参数量。

边界框回归损失对微小定位偏差的优化能力不足:采用 CIoU 损失,在高 IoU (>0.8) 区域梯度趋零。对于 30×30 像素的目标,1 像素偏移即导致 IoU 下降 $>10\%$,但此时梯度已近零,模型难以进一步优化定位精度。

上述问题相互关联:特征表达能力不足会影响检测头对目标信息的利用,进而削弱边界框回归的优化

效果,最终导致漏检、误检及定位偏差等问题。因此,有必要从注意力机制、检测头结构以及损失函数三个层面进行系统性协同优化,以实现模型整体性能的提升。

2 YOLOv11n 模型改进

针对无人机在复杂环境下小目标检测面临的尺度微小、背景干扰强、伪装效应显著三大核心挑战,本文对 YOLOv11n 基线模型进行了三方面的系统性改进。整体架构对骨干网络、颈部特征融合路径及回归损失函数均进行了针对性优化,旨在构建一个高效且鲁棒的检测模型。

提出的三项改进模块与 YOLOv11n 基线模型的交互关系及接口说明如下:

(1) C2PSA-TripleAttention 模块位于骨干网络末端,替换原 YOLOv11n 中的 C2PSA 模块。其输入接口为 SPPF 模块输出的特征图 ($20 \times 20 \times 512$),输出接口为送往颈部 FPN 的特征图,尺寸同样为 $20 \times 20 \times 512$ 。输入输出尺寸与通道数与原 C2PSA 完全一致,因此无需调整前后网络层的连接方式,可实现无缝嵌入。

(2) Detect-MBConv 检测头位于颈部之后,替换原 YOLOv11n 的检测头结构。该模块新增了 P2 高分辨率分支,其输入直接来自骨干网络第 4 层的特征图 ($160 \times 160 \times 128$);同时保留了 P3 分支 (输入来自颈部 PAN 输出的特征图, $80 \times 80 \times 256$) 和 P4 分支 ($40 \times 40 \times 512$),并移除了原 P5 大目标分支。检测头内部采用 MBConv 轻量化卷积,将标准 3×3 卷积的计算量降低。

(3) Focaler-IoU 损失函数置于检测头之后,替换原 YOLOv11n 中的 CIoU 损失函数。其输入接口为检测头输出的预测边界框和数据集中标注的真实边界框,输出接口为一个回归损失值,用于反向传播更新网络参数。聚焦区间下界 $d=0$ 、上界 $u=0.95$,使模型拥有更快的收敛速度。

如图 1 所示。在该结构图中,绿色框 (Add) 表示新增的模块,红色框 (Delete) 表示移除的模块,Replace 表示对原始模块进行替换。




图1 本文提出的轻量化无人机检测网络整体架构

Fig.1 Overall architecture of the proposed lightweight UAV detection network

2.1 C2PSA-TripleAttention 模块

远距离下的无人机目标通常具有目标尺度小、纹理信息弱和背景干扰强等特点。因此,特征提取网络需具备抑制背景干扰并有效建模目标正交几何结构的能力。然而,现有注意力机制在此类任务中表现有限。通道注意力如压缩与激励网络(Squeeze-and-Excitation Networks, SE)主要关注通道间的全局响应,缺乏对空间结构信息的建模能力;混合注意力如卷积块注意力模块(Convolutional Block Attention Module, CBAM)虽然依次计算通道与空间注意力^[14],但两者独立进行,

难以捕捉通道与空间维度间的耦合关系。在目标与背景频谱重叠时无法有效激活微弱但具有方向性的结构特征。YOLOv11 中的 C2PSA 模块虽通过分组卷积与轻量注意力实现高效上下文感知,其内部的位置敏感注意力(Position-Sensitive Attention, PSA)仍以空间显著性为主导,对通道与空间维度的联合依赖建模不足,当无人机与天空或树林等背景具有较高相似性时,其目标响应易被背景噪声干扰。

针对上述问题,本文在 C2PSA 的增强路径中深度集成 TripleAttention^[15],构建 C2PSA-TripleAttention 融合模块。该模块的整体结构如图 2 所示。




图2 C2PSA-TripleAttention 融合模块结构图

Fig.2 Structure Diagram of C2PSA-TripleAttention Fusion Module

每个 PSABlock-Triple 的核心改进在于将原 PSA 单元替换为 TripleAttention。如图 3 所示, 三重注意力机制采用三路并行分支分别进行正交方向特征建模: 在通道-宽度 (C-W) 平面生成注意力以强化水平方向的特征响应 (如机身连续性), 在高度-通道 (H-C) 平面生成注意力以突出垂直方向的特征响应 (如旋翼延伸), 并

在高度-宽度 (H-W) 平面生成空间注意力以定位显著区域。三路输出经维度还原后等权重相加融合:

$$Y = \frac{1}{3}(F_{C-W} + F_{H-C} + F_{H-W}) \quad (1)$$

经多层非线性变换与残差连接后, 增强特征与路径 A 拼接, 并通过 1×1 卷积压缩输出。




图 3 三重注意力机制

Fig.3 Triple attention mechanism

该设计在几乎不增加额外参数的情况下, 实现了通道与空间信息之间的跨维度交互, 显著增强了模型对无人机旋翼正交结构的感知能力。在架构兼容性方面, 模块保留了 C2PSA 的输入/输出接口及整体流程, 可无缝嵌入 YOLOv11 骨干网络, 无需调整拓扑结构。

在计算效率方面, 仅对半数通道施加复杂注意力运算。设 C2PSA 模块的总计算量为 T , 其中: 复杂注意力部分 (PSA) 的计算量为 A , 其他固定操作 (卷积、拼接、残差等) 的计算量为 B , 则有:

$$T = A + B \quad (2)$$

C2PSA-TripleAttention 模块的核心改动:

1. 将 PSA 替换为 TripleAttention, 两者计算量相当 (均为轻量线性注意力), 即 $A_{TA} \approx A$;
2. 仅对半数通道施加该注意力, 另一半通道直接跳过。

因此新模块的注意力计算量减半, 固定操作 B 保持不变:

$$T^* = \frac{1}{2}A + B \quad (3)$$

计算量降低量为:

$$\Delta T = T - T^* = A - \frac{1}{2}A = \frac{1}{2}A > 0 \quad (4)$$

理论分析及实测结果表明, 该模块较原 C2PSA 模块计算量降低约 33% (从 120MFLOPs 降至 80.64MFLOPs), 进一步验证了其高效性。更重要的是,

C-W 与 H-C 注意力分支协同建模无人机旋翼的正交几何特性: C-W 分支强化水平机身特征, H-C 分支突出垂直旋翼特征。当目标与背景频谱重叠、纹理缺失时, 两路分支的一致性响应仍能稳定激活目标区域, 有效抑制伪装效应引起的背景干扰。

得益于上述机制, C2PSA-TripleAttention 在骨干网络深层 (SPPF 之后) 输出高判别性、低噪声的特征表示, 有效增强检测头对微小目标的定位与分类鲁棒性, 为后续检测头实现精确定位提供了更加可靠的特征表示。

2.2 Detect-MBConv

复杂背景下, 无人机目标尺度可能小至 8 像素以下。经骨干网络 5 次下采样后, YOLOv11 原始 P3-P5 特征图上目标响应被压缩至单点甚至消失, 漏检严重。该问题的根源在于检测头尺度体系与目标实际尺度分布严重失配。P5 分支专为大目标设计, 对小目标检测无益且增加参数量; 与此同时, 含有丰富空间细节的高分辨率特征 (如 C2 层, 160×160) 未被有效利用。

为此, 本文对检测头与颈部网络进行协同重构, 具体内容如下^[16-17]:

首先引入 P2 高分辨率分支 (160×160)。其输入来自骨干第 4 层, 使小于 8 像素目标的特征有效面积提升近 4 倍; 同时移除冗余的 P5 分支, 形成 P2/P3/P4 三级结构 (分别对应小于 16 像素、16~32 像素、32~64

像素的目标)。

其次颈部采用双向信息流: 深层语义逐级向上引导 $P4 \rightarrow P3 \rightarrow P2$; 同时在 $P2$ 前的 $C3k2$ 模块中启用残差连接, 形成梯度跳跃路径, 防止微弱结构被过度平滑。

通道数随分辨率提高而递减: $P4$ 、 $P3$ 、 $P2$ 通道数分别设为 512、256、128, 兼顾深层语义编码与浅层计算效率。

最后检测头的回归分支采用 MBConv 轻量化结构, 通过深度可分离卷积降低 3×3 卷积 75% 计算量, 并引入 SE 模块增强关键通道特征, 在保持高分辨率感知的同时降低参数量。

为量化上述轻量化效果, 考虑一个标准 3×3 卷积, 其计算量 (FLOPs) 可表示为:

$$K^2 \times C_{in} \times C_{out} \times H \times W \quad (5)$$

其中 $K=3$ 为卷积核尺寸, C_{in} 和 C_{out} 分别为输入、输出通道数。

深度可分离卷积将其分解成深度卷积和逐点卷积。总计算量为:

$$K^2 \times C_{in} \times H \times W + C_{in} \times C_{out} \times H \times W \quad (6)$$

假设二者比值为 r , 则有:

$$r = \frac{1}{C_{out}} + \frac{1}{K^2} \quad (7)$$

取 $K=3$, 不同输出通道数下的计算结果如表 1 所示。

表 1 深度可分离卷积计算量对比

Table 1 Comparison of computational cost of depthwise separable convolution

C_{out}	r	计算量降低比例 (1-r)
8	0.2361	76.4%
16	0.1736	82.6%
32	0.1424	85.8%
64	0.1267	87.3%
128	0.1189	88.1%

由表 1 可见, 当输出通道数 $C_{out} \geq 32$ 时, 深度可分离卷积的理论计算量降低比例均超过 85%。本文所采用的 MBConv 块还包含 1×1 扩展卷积 (扩展因子为 6) 及 SE 注意力模块, 这些操作会引入少量额外计算。综合检测头中各层通道数 (32 ~ 512) 及 MBConv 完整结构, 平均计算量降低约 75%。

改进后的网络模型构成一个紧密耦合的感知体系: $P2$ 分支提供高保真空间感知, 双向融合注入语义先验, 通道递减控制资源消耗。该设计无需引入额外模块或复杂结构, 仅通过尺度重配与路径优化, 即可

在保持模型轻量化的同时, 显著提升对空中微小无人机的检测鲁棒性。

2.3 Loss Function

针对传统边界框回归^[18]损失在无人机小目标检测中对极小目标关注不足、高 IoU 区域梯度趋近于零的问题, 本文引入 Focaler-IoU 损失函数。该损失函数通过设置关注区间对 IoU 进行分段映射, 当 IoU 值处于该区间内时, 损失函数增强其梯度贡献, 使模型更加关注这部分样本; 而对于 IoU 值较高、预测已较准确的样本, 则相对降低关注程度^[19]。

设预测框与真实框之间的 IoU 值为 IoU , 关注区间为 d 到 u , 则 Focaler-IoU 的映射计算方式如下:

$$IoU_{focaler} = \begin{cases} 0 & IoU < d \\ \frac{IoU - d}{u - d} & d \leq IoU \leq u \\ 1 & IoU > u \end{cases} \quad (8)$$

其中, d 表示关注区间的下限, u 表示关注区间的上限。通过该区间映射机制, 可以对不同质量样本进行更加合理的权重分配, 使模型训练过程更加关注关键样本。相应地, 损失函数为:

$$L_{Focaler-IoU} = 1 - IoU_{focaler} \quad (9)$$

在实际应用中, Focaler-IoU 损失函数的效果与区间参数的设置密切相关。不同检测任务中, 关注区间的选择会影响模型训练过程中所强调的样本类型。因此, 需要根据具体任务特点对参数进行合理设置。基于 DUT 数据集统计分析, 本文设置 $d=0.00$ 、 $u=0.95$ 。该映射关系如图 4 所示。




图 4 Focaler-IoU 映射曲线 ($d=0, u=0.95$)

Fig.4 Focaler-IoU loss function mapping curve ($d=0, u=0.95$)

这一设置的依据在于: 一方面, 无人机小目标在图像中占比极小, 初始预测框与真实框的 IoU 常低于 0.1, 属于典型的困难样本。若设置 $d>0$, 将丢失大量潜在可修正的难样本, 因此设置 $d=0$ 以保留所有优化

机会。另一方面,当 $\text{IoU} > 0.95$ 时,预测框与真实框的定位误差通常小于 0.5 像素,进一步优化的边际收益极低,且可能导致过拟合。因此设置 $u=0.95$,使损失在 $\text{IoU} > 0.95$ 时归零,避免在已精确定位的样本上浪费训练资源。

在 $0 \leq \text{IoU} \leq 0.95$ 的线性映射区间内,损失函数对 IoU 的变化梯度恒为 $1/(u-d) \approx 1.053$ 。该恒定梯度使模型在中等重叠度区间持续获得稳定的优化信号,有效解决了传统 CIoU 损失在高 IoU 区域梯度趋近于零、难以在训练后期对微小定位偏差进行持续优化。

相比 CIoU 损失, Focaler-IoU 结合合理的参数设置,使模型在训练过程中更合理地分配梯度资源,聚焦于困难样本,从而在保持整体检测性能稳定的同时,有效提升小目标边界框回归精度。

3 实验分析

3.1 实验数据集

本文采用公开的 DUT 反无人机数据集(DUT Anti-UAV Dataset)进行模型训练与评估^[20]。该数据集由大连理工大学团队发布,专注于可见光条件下的无人机检测与跟踪任务。数据集包含检测和跟踪两个子集,其中检测子集共 10,000 张图像,划分为训练集 5200 张、验证集 2600 张、测试集 2200 张,分别包含 5243、2621 和 2245 个无人机标注实例。数据集涵盖 35 余种无人机型号,场景高度多样,包括天空、丛林、高层建筑群、居民区、农田及操场等;同时覆盖黎明、白天、黄昏、夜晚等多种光照条件,以及晴天、阴天、雪天等天气变化。

该数据集的突出特点是小目标比例显著高于传统数据集。据统计,无人机边界框面积占比最小为 1.9×10^{-6} ,最大为 0.70,平均约为 1.3% (0.013),超过 80% 的样本面积占比小于 0.05。目标空间分布显示,无人机中心多集中于图像中心区域,但在水平和垂直方向分布相对均匀。该数据集兼具极小尺度、强背景干扰与环境动态性等特点,是验证本方法在复杂场景下鲁棒性与精度的理想基准。

3.2 实验环境与参数配置

为确保网络性能评估的公平性与可比性,所有实验均在配备 Intel i9-13900K CPU、32GB 内存及 NVIDIA GeForce RTX 4090 GPU 的工作站上完成,操作系统为 Windows 11,深度学习框架采用 PyTorch 2.7.1。模型训练采用 SGD 优化器,初始学习率设为 0.01,并采用余弦退火策略衰减至 0.001;权重衰减系

数为 0.0005,动量因子为 0.937。训练周期 (Epochs) 为 200 轮,批量大小 (Batch Size) 为 16,输入图像尺寸统一调整为 640×640 。为加速收敛,前 3 个周期采用学习率预热 (Warmup) 策略。

训练阶段启用了 Mosaic 拼图增强、MixUp 混合增强、色彩扰动、随机水平翻转、尺度缩放与平移变换等多种数据增强策略,以提升样本多样性及模型鲁棒性。

在实验中,统一选择 YOLOv11n 作为基准模型,原因在于其参数量少、计算复杂度低,在保持基本检测能力的同时具备优异的推理效率,特别适合作为面向边缘端部署的改进基线。

3.3 评价方法

为定量评估所提方法在微小无人机目标检测任务中的性能与模型复杂度,本文采用查准率 (Precision, P)、查全率 (Recall, R)、 $\text{mAP}@0.5$ 、 $\text{mAP}@0.5:0.95$ 以及参数量 (Parameters) 五项指标作为综合评价标准。其中, Precision 衡量检测结果的准确性, Recall 反映模型对真实目标的覆盖能力; $\text{mAP}@0.5$ 表示在 IoU 阈值为 0.5 时的平均精度,侧重评估模型在宽松定位条件下的整体表现; $\text{mAP}@0.5:0.95$ 则是在 IoU 从 0.5 到 0.95 以 0.05 为步长的多个阈值下平均精度的均值; Parameters 用于衡量模型的规模与计算负担,便于在精度与效率之间进行权衡分析。相关指标计算公式如下:

$$P = \frac{TP}{TP + FP} \quad (10)$$

$$R = \frac{TP}{TP + FN} \quad (11)$$

$$\text{mAP} = \frac{\sum_{i=1}^{\text{classes}} \text{AP}_i}{\text{classes}} = \frac{\sum_{i=1}^{\text{classes}} \int P(R) d(R)}{\text{classes}} \quad (12)$$

3.4 对比实验

为验证所提算法在无人机小目标检测任务中的有效性,将其与当前主流轻量级及高精度目标检测模型进行系统对比,包括 YOLOv3-Tiny、YOLOv5n、YOLOv8n、YOLOv9c、YOLOv10n、YOLOv11n、YOLOv13n 以及 RT-DETR-L^[21]等,结果如表 2 所示。

在 DUT 测试集上,本文方法以仅 1.68M 参数量和 6.2GFLOPs 的计算开销,实现了 $\text{mAP}@0.5=90.2\%$ 、 $\text{mAP}@0.5:0.95=57.9\%$ 、 $\text{Recall}=84.1\%$ 的综合性能,全面优于所有对比模型。相较于基线 YOLOv11n

($\text{mAP}@0.5:0.95=51.2\%$, $\text{Recall}=73.1\%$), 本方法在 $\text{mAP}@0.5:0.95$ 上提升 6.7 个百分点, 在 Recall 上提升 11.0 个百分点, 表明其在抑制漏检与提升定位鲁棒性方面具有显著优势。

值得注意的是, 尽管 YOLOv8n 和 YOLOv10n 的参数量 (分别为 2.6M 和 2.3M) 略高于本方法, 但其 $\text{mAP}@0.5:0.95$ 上分别低 4.2 和 3.8 个百分点, 表明本方法在保持更低复杂度的同时实现了更高的检测精度。

此外, 本方法在 $\text{mAP}@0.5:0.95$ 上超越了参数量高达 108M 的 RT-DETR-L (54.5%), 表明在极端小目标场景下, 任务驱动的结构设计与损失优化比单纯扩大模型容量更为高效。尽管 YOLOv9c 在 $\text{mAP}@0.5:0.95$ 上略高于本方法 (58.5% vs 57.9%), 但其参数量高达 103.7M, 不利于边缘端部署。本方法在精度相近的条件下实现了极致的轻量化, 更适合资源受限场景。

表 2 不同模型实验结果对比

Table 2 Test results of different models

模型	P	R	$\text{mAP}@0.5$	$\text{mAP}@0.5-0.95$	FLOPs(Giga)	Params(Million)
YOLOv3-Tiny	88.9	49.9	58.8	35.9	19.0	12.1
YOLOv5n	92.3	72.9	81.3	50.5	7.2	2.5
YOLOv6	93.0	72.2	81.4	49.2	11.9	4.2
YOLOv8n	93.4	75.1	83.1	52.5	8.2	3.0
YOLOv9c	93.4	80.5	87.4	58.5	25.5	103.7
YOLOv10n	91.2	73.2	82.2	51.3	8.4	2.7
YOLOv10s	91.2	77.8	85.3	55.0	24.8	8.0
YOLOv11n	93.2	73.1	81.9	51.2	6.4	2.59
RTDETR	88.6	82.7	87.0	54.5	32.8	108
YOLO12n	90.6	72.7	81.1	50.6	6.5	2.5
YOLO13n	91.1	72.9	80.8	54.6	6.4	2.4
Ours	96.3	84.1	90.2	57.9	6.2	1.68

3.5 消融实验

为验证各改进模块对模型性能的贡献, 设计消融实验进行测试与评价, 结果如表 3 所示。其中“√”表示

启用该模块, “×”表示未启用。表 3 的消融实验结果证明了各改进模块的有效性。

表 3 消融实验结果对比

Table 3 Comparison of ablation experiment results

Focaler-IoU	Detect-MBConv	Triple-Attention	Precision	Recall	$\text{mAP}@0.5$	$\text{mAP}@0.5-0.95$	Params (Million)	FLOPs (Giga)
×	×	×	0.932	0.731	0.819	0.512	2.59	6.4
√	×	×	0.934	0.735	0.830	0.528	2.59	6.4
×	√	×	0.964	0.838	0.9	0.577	1.73	6.3
×	×	√	0.948	0.775	0.864	0.55	2.53	6.4
√	√	√	0.963	0.841	0.902	0.579	1.68	6.2

单独引入 Detect-MBConv 检测头 (表 3 第 3 行) 后, 相比基线 (第 1 行), Precision 从 93.2% 提升至 96.4%, Recall 从 73.1% 提升至 83.8%, $\text{mAP}@0.5$ 从 81.9% 提升至 90.0%, $\text{mAP}@0.5:0.95$ 从 51.2% 提升至 57.7%。参数量从 2.59M 降至 1.73M, FLOPs 从 6.4 降至 6.3。该模块显著提升了检测精度与召回率, 同时降低了模型复杂度。

单独引入 C2PSA-TripleAttention 模块 (表 3 第 4 行) 后, 相比基线, Precision 提升至 94.8%, Recall 提

升至 77.5%, $\text{mAP}@0.5$ 提升至 86.4%, $\text{mAP}@0.5:0.95$ 提升至 55.0%。参数量略降至 2.53M, FLOPs 保持 6.4 不变。该模块在不增加计算开销的前提下有效提升了检测精度。

同时使用 Detect-MBConv 检测头、C2PSA-TripleAttention 模块和 Focaler-IoU 损失函数 (表 3 第 5 行), 相比仅使用 Detect-MBConv (第 3 行), $\text{mAP}@0.5:0.95$ 从 57.7% 进一步提升至 57.9%, Recall 从 83.8% 微增至 84.1%, Precision 略有回调但仍保持

96.3%；参数量进一步降至 1.68M，FLOPs 降至 6.2。相比基线（第 1 行），完整方法在 Precision、Recall、mAP@0.5 和 mAP@0.5:0.95 上分别提升 3.1、11.0、8.3 和 6.7 个百分点，同时参数量减少 35.5%，FLOPs 降低 0.2。

上述结果表明，三项改进在精度与轻量化方面均具有正向贡献，且协同使用可获得最优综合性能。值得注意的是，三项改进联合使用时参数量为 1.68M，低于单独使用 Detect-MBConv 的 1.73M。这是因为 Detect-MBConv 和 TripleAttention 均具有轻量化效果，两者参数削减产生叠加。

3.6 不同注意力机制对比实验

为验证 C2PSA-TripleAttention 的有效性，将其与 CA、SE、SimAM、CBAM 等注意力机制进行对比，并通过分支消融实验验证三路正交分支的贡献，结果如表 4 所示。

表 4 不同注意力机制对比实验结果

Table 4 Experimental results of different attention mechanisms

注意力机制	P	R	mAP@0.5	mAP@0.5-0.95
YOLOv11n	0.932	0.731	0.819	0.512
CA	0.925	0.716	0.809	0.506
SE	0.907	0.719	0.813	0.499
SimAM	0.915	0.725	0.813	0.507
CBAM	0.899	0.737	0.814	0.502
禁用 C-W	0.949	0.783	0.86	0.55
禁用 H-C	0.944	0.783	0.862	0.553
禁用 H-W	0.951	0.786	0.863	0.55
Triple-Attention	0.948	0.775	0.864	0.55

(1) 不同注意力机制对比

将 YOLOv11n 中的 C2PSA 模块替换为 CA、SE、SimAM、CBAM 等注意力机制进行对比。结果表明，这些方法对基线模型的提升均十分有限，mAP@0.5 几乎无增长，部分机制甚至出现轻微下降。这一现象说明，单一维度（仅通道或仅空间）或串行堆叠的注意力结构，难以建立通道与空间之间的跨维度联合依赖，当无人机目标与背景纹理频谱重叠时，微弱的正交结构特征无法被有效激活。

本文提出的 TripleAttention 在所有指标上均显著优于上述对比方法，mAP@0.5 较基线提升 4.5 个百分点。其优越性源于三路并行结构：C-W 分支沿水平方向建模机身连续性，H-C 分支沿垂直方向突出旋翼延伸特征，H-W 分支提供空间位置约束。三者协同使模型能够在三个平面上同时建立跨维度交互，有效提取无人机旋翼的正交几何结构，从而在复杂背景中准确区分伪装目标。

(2) 三支消融实验

对 TripleAttention 的三条分支分别进行禁用实验，完整模型性能最佳，禁用任一分支后 mAP@0.5 均出现下降。其中禁用 C-W 分支（水平机身特征）性能损失最大，禁用 H-C 分支（垂直旋翼特征）次之，禁用 H-W 分支（空间定位）损失最小。这一梯度关系与无人机目标的几何特性高度吻合：旋翼的十字交叉结构决定了水平和垂直方向的特征响应最为关键，空间定位信息在 C-W 和 H-C 分支已提供位置约束的情况下，边际收益相对有限。三路分支同时工作时性能最优，验证了正交几何协同建模的有效性。

3.7 不同损失函数对比实验

为验证 Focaler-IoU 的有效性，将其与 CIoU、DIOU、EIoU、SIoU、GIoU 等损失函数进行对比。

表 5 不同损失函数对比实验结果

Table 5 Experimental results of different loss functions

损失函数	P	R	mAP@0.5	mAP@0.5-0.95
CIoU	0.932	0.731	0.819	0.512
DIOU	0.904	0.75	0.824	0.517
EIoU	0.92	0.746	0.824	0.517
SIoU	0.925	0.741	0.821	0.511
GIoU	0.93	0.736	0.822	0.516
Focaler-IoU	0.934	0.735	0.830	0.528

如表 5 所示，Focaler-IoU 在 Precision、mAP@0.5 和 mAP@0.5:0.95 上均取得最优值，验证了其在无人机小目标检测任务中的有效性。其优越性可归因于分段映射机制：传统损失函数对全区间 IoU 进行优化，当预测框与真实框重叠度较高时梯度自然衰减，模型难以继续精调边界框；而 Focaler-IoU 通过聚焦[0,0.95]区间内的中等难度样本，在该区间内保持恒定梯度，使模型在训练后期仍能获得有效的优化信号，持续修正微小的定位偏差，从而在更严格的高 IoU 阈值下取得更优的定位精度。

4. 可视化实验与结果分析

为更全面验证本文方法的有效性，本节结合检测结果可视化与热力图进行分析。分析从三个方面展开：复杂背景下的目标特征提取能力、极小目标检测能力及目标定位精度，分别对应 C2PSA-TripleAttention 模块、Detect-MBConv 检测头与 P2 高分辨率分支以及 Focaler-IoU 损失函数。

4.1 C2PSA-TripleAttention 模块分析

为进一步验证本文改进算法在复杂环境下的有效性，本文采用了梯度加权类激活映射（Grad-CAM）技术对模型的注意力区域进行可视化展示。如图 5 至图 7 所示，我们将基线模型（Baseline）与引入注意力机

制后的改进模型在不同干扰场景下的检测结果及热力

图进行了对比分析。




图5 云层干扰场景下对比图

Fig.5 Comparison under cloud interference scenario




图6 树叶遮挡场景下对比图

Fig.6 Comparison under leaf occlusion scenario



图7 房屋干扰场景下对比图

Fig.7 Comparison under building interference scenario

如图5所示,在云层背景下,基线模型(图5a,5c)易受云团误导,热力图显示模型主要关注背景噪声而非目标本身,导致漏检。相比之下,改进模型(图5b、5d)有效抑制了云层背景响应,将注意力精准聚焦于无人机目标,成功实现检测。

图6展示了极具挑战性的树叶遮挡场景。基线模型(图6a,6c)受限于茂密植被的纹理干扰,无法捕捉到被部分遮挡的无人机特征,热力图分散且未覆盖目标区域。改进模型(图6b,6d)展现出了更强的特征穿透力,热力图清晰地定位到了隐藏在树丛中的无人机。表明改进后的网络能够有效利用局部几何先验信息,缓解严重遮挡导致的特征湮灭问题。


在建筑物林立的场景中(图7),背景中存在大量类似无人机颜色或形状的窗框、阳台等结构。基线模型(图7a,7c)虽然检测到目标,但热力图显示其对背景建筑也有较高的响应,存在虚警风险。改进模型(图7b,7d)则表现出更纯粹的目标关注度,显著降低了背景杂波的干扰,检测框更贴合目标。

上述可视化结果证明,本文改进策略能够有效引

导模型关注真正的目标区域,显著抑制复杂背景带来的噪声干扰。尤其在纹理缺失的云层和树叶间隙区域,改进模型仍能形成稳定目标响应,表明C2PSA-TripleAttention模块能够在纹理缺失区域重建判别性结构响应,从根本上抑制伪装干扰。

4.2 P2 高分辨率分支分析

图8展示了两个极小无人机目标(目标1约 8×5 像素,目标2约 11×5 像素)的检测结果与热力图对比。每组包含:(a)(c)基线模型结果、(b)(d)改进模型结果。



(a) 目标1(基线模型)

(b) 目标1(改进模型)




图8 P2检测头热力图分析

Fig.8 Heatmap analysis of the P2 detection head

如图8a与图8b所示：基线模型（图a）经多次下采样后，深层特征图中目标信息严重丢失，热力图响应区域发散、模糊，无法精确覆盖目标本体。相比之下，引入P2分支的改进模型（图b）利用其高分辨率特征图（160×160），成功保留了目标的边缘与纹理细节。热力图高响应区域紧密包裹目标，证明P2层有效增强了模型对微小空间信息的感知能力。

在图8c与图8d中，背景包含复杂建筑与天空纹理。基线模型（图c）的热力图存在明显的背景误激活现象，说明低分辨率特征难以区分微小目标与背景噪声。改进模型（图d）通过P2分支引入了更丰富的浅层细节信息，显著抑制了背景区域的响应强度，使注意力高度集中于目标本身。

上述结果进一步表明：基线模型中极小目标的特征在深层网络中已显著衰减；而新增的P2高分辨率分支保留了浅层空间细节，使小于8像素目标得以被感知。

定量上，表3显示加入Detect-MBConv后召回率从73.1%提升至83.8%。同时，该检测头采用深度可分离卷积，整体FLOPs从6.4降至6.2，参数量从2.59M降至1.68M，实现了细节保留与计算量降低的协同优化。

可视化结果证明，P2高分辨率检测头能够有效缓解微小目标在下采样过程中的特征湮灭问题，显著提升模型在复杂场景下的定位精度与鲁棒性。

4.3 Focaler-IoU 损失函数分析

为分析Focaler-IoU对边界框回归的影响，对比其与CIoU、DIoU、EIoU、SIoU、GIoU在训练集与验证集上的损失曲线进行对比。




图9 训练阶段损失函数曲线对比

Fig.9 Comparison of training loss curves




图10 验证阶段损失函数曲线对比

Fig.10 Comparison of validation loss curves

如图9所示，前40个epoch各损失函数下降速度相近。约60个epoch后，Focaler-IoU曲线开始明显低于其他损失，并持续缓慢下降。CIoU、DIoU、EIoU、SIoU、GIoU的曲线在80个epoch后趋于平坦，损失值稳定在1.3-1.5之间；而Focaler-IoU在200个epoch时仍略有下降，最终稳定在0.94左右。

如图10所示，Focaler-IoU同样保持最低的验证损失（约0.95），且曲线波动幅度小于其他损失函数。其他损失函数的验证损失在1.2-1.5之间，且后期有小幅振荡。

上述曲线表明：传统损失函数在训练后期梯度趋近于零，模型难以进一步优化；Focaler-IoU在整个训练过程中保持有效梯度，能够持续减小边界框回归误差。这与表5中Focaler-IoU相比CIoU在mAP@0.5:0.95上提升1.6%相一致，表明高IoU阈值下的定位精度得到改善。验证了Focaler-IoU通过设置聚焦区间[0,0.95]，聚焦中等难度样本，能够持续优化微小定位误差，有效突破了传统损失函数在高重叠区梯度消失的问题。

5 结束语

针对复杂环境下无人机小目标检测面临的尺度

微小、背景干扰强和伪装效应等显著等挑战, 本文提出一种任务驱动的轻量化协同优化架构。核心创新在于将无人机特有的正交几何先验显式融入注意力机制, 并围绕“感知-表达-优化”三个环节进行系统性结构重设计, 而非孤立改进。实验结果表明, 在无人机目标

检测中, 本方法以 1.68M 参数、6.2GFLOPs 的极低开销, 实现了 90.2% $\text{mAP}@0.5$ 的检测精度, 在轻量化与高精度之间取得了超越现有方案的优异平衡。未来工作将探索多模态知识蒸馏与动态网络剪枝, 进一步压缩模型, 以适应更严苛的边缘端部署环境。

参考文献

- [1] 李旻姝, 周莫涵, 支瑞聪. 基于多模态融合的无人机识别研究综述[J]. 计算机工程与应用, 2025, 61(21): 1-14.
LI M S, ZHOU M H, ZHI R C. Research Review of UAV Recognition Based on Multi-Modal Fusion[J]. Computer Engineering and Applications, 2025, 61(21): 1-14.
- [2] Wei Y, Hong T, Fang C. Research on information fusion of computer vision and radar signals in uav target identification[J]. Discrete dynamics in nature and society, 2022, 2022(1): 3898277.
- [3] Chipier F-L, Martian A, Vlădeanu C, et al. Drone detection and defense systems: Survey and a software-defined radio-based solution[J]. Sensors, 2022, 22(4): 1453.
- [4] Isaac-Medina B K, Poyser M, Organisciak D, et al. Unmanned aerial vehicle visual detection and tracking using deep neural networks: A performance benchmark[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 1223-1232.
- [5] Liu Z, An P, Yang Y, et al. Vision-based drone detection in complex environments: A survey[J]. Drones, 2024, 8(11): 643.
- [6] Wang C, Tian J, Cao J, et al. Deep learning-based UAV detection in pulse-Doppler radar[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-12.
- [7] Serageldin A F, Elsayed H A, Abdel-Hamid L. Real-Time UAV Detection Using an Enhanced YOLO v8 Model[C]//2025 42nd National Radio Science Conference (NRSC). IEEE. 2025: 193-201.
- [8] 王迎龙, 孙备, 丁冰, 等. BG-YOLO:复杂大视场下低慢小无人机目标检测方法[J]. 仪器仪表学报, 2025, 46(2): 255-266.
WANG Y L, SUN B, DING B, et al. BG-YOLO: A low-altitude slow-moving small UAV targets detection method in complex large field of view[J]. Chinese Journal of Scientific Instrument, 2025, 46(2): 255-266.
- [9] Lai D, Kang K, Xu K, et al. Enhancing UAV object detection with an efficient multi-scale feature fusion framework[J]. PLoS One, 2025, 20(10): e0332408.
- [10] Mi C, Chen Y, Zhu L, et al. CAFE-YOLO: an object detection algorithm from UAV perspective fusing channel attention and fine-grained feature enhancement[J]. Scientific Reports, 2025, 15(1): 35083.
- [11] Fang H, Wu C, Bai K, et al. Infrared UAV Target Tracking with Dynamic Feature Refinement and Global Contextual Attention Knowledge Distillation[J]. IEEE Transactions on Multimedia, 2026: 1-13.
- [12] 袁鸿, 刘永明, 史晨阳. 基于 EED-YOLOv8n 的无人机目标检测方法研究[J]. 宁夏师范大学学报, 2025, 46(04): 71-81.
YUAN H, LIU Y M, SHI C Y. Research on small object detection method for unmanned aerial vehicles based on EED-YOLOv8n[J]. Journal of Ningxia Normal University, 2025, 46(04): 71-81.
- [13] Khanam R, Hussain M. Yolov11: An overview of the key architectural enhancements[J]. arXiv preprint arXiv:2410.17725, 2024.
- [14] Woo S, Park J, Lee J-Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [15] Misra D, Nalamada T, Arasanipalai A U, et al. Rotate to attend: Convolutional triplet attention module[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2021: 3139-3148.

- [16] 王燕妮, 胡敏, 韩世鹏, 等. 多尺度和多层次特征融合的人体姿态估计[J]. 计算机工程与应用, 2025, 61(06): 199-209.
WANG Y N, HU M, HAN S P, et al. Human Pose Estimation with Multi-Scale and Multi-Level Feature Fusion[J]. Computer Engineering and Applications, 2025, 61(06): 199-209.
- [17] 秦乐, 谭泽富, 雷国平, 等. EMF-YOLO:轻量化多尺度特征提取路面缺陷检测算法[J]. 计算机工程与应用, 2025, 61(14): 101-111.
QIN L, TAN F Z, LEI G P, et al. EMF-YOLO: Lightweight Multi-Scale Feature Extraction Algorithm for Road Surface Defect Detection[J]. Computer Engineering and Applications, 2025, 61(14): 101-111.
- [18] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [19] Wang Y, Wang H, Xin Z. Efficient detection model of steel strip surface defects based on YOLO-V7[J]. IEEE Access, 2022, 10: 133936-133944.
- [20] Zhao J, Zhang J, Li D, et al. Vision-based anti-UAV detection and tracking[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 25323-25334.
- [21] Zhao Y, Lv W, Xu S, et al. Detsr beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF Conference on computer vision and pattern recognition. 2024: 16965-16974